



IA de Dosimetria Penal

Plano detalhado do projeto: escopo, fundamentos jurídicos, arquitetura, tecnologias, fases de construção, avaliação e implantação no Azure

Item	Descrição
Autor	Sérgio
Versão	1.0 — 22 de setembro de 2026
Público do sistema	Estudantes de Direito e instituições do sistema de justiça
Escopo inicial (MVP)	Furto (art. 155 do CP) e roubo (art. 157 do CP)
Hospedagem	Microsoft Azure (conta Azure for Students), região Brazil South

Como usar este documento. Ele descreve o quê construir, em que ordem e por quê, mas não entrega código pronto: a implementação é sua. Cada fase termina com um critério de pronto objetivo e uma pergunta para você responder antes de começar a codar.

Sumário

1. Visão geral	3
2. Escopo	3
3. Fundamento jurídico que o sistema modela	4
4. Arquitetura	6
5. Tecnologias	7
6. Modelo de dados	8
7. Contratos entre os componentes	9
8. Fases de construção	10
9. Avaliação	14
10. Infraestrutura no Azure	15
11. Segurança, LGPD e governança	16
12. Estrutura do repositório (sugestão)	16
13. Riscos e mitigação	17
14. Fontes oficiais	17
15. Glossário	18

1. Visão geral

O sistema recebe a descrição de um caso penal em texto livre, identifica o crime e as circunstâncias relevantes, calcula a faixa de pena seguindo o **sistema trifásico** do art. 68 do Código Penal e devolve um relatório que explica cada passo do cálculo, citando os dispositivos reais do Código Penal (CP) e da Constituição Federal (CF).

O princípio de projeto que guia tudo é a separação entre **interpretar** e **calcular**. Modelos de linguagem (LLMs) são bons para ler texto e escrever explicações, mas erram contas e inventam artigos com facilidade. Por isso o LLM só lê e escreve; quem calcula a pena é um motor de regras escrito por você, determinístico, testável e auditável.

1.1 O que o sistema é

Aspecto	Descrição
Ferramenta de ensino	Permite que o aluno faça a dosimetria e compare com o cálculo do sistema, fase por fase.
Ferramenta de apoio	Oferece a instituições uma sugestão fundamentada e rastreável, sempre sujeita a revisão humana.
Sistema explicável	Todo número do resultado vem acompanhado da regra e do dispositivo que o produziu.

1.2 O que o sistema não é

Não é	Por quê
Um juiz automático	A decisão é sempre humana. A Resolução CNJ 615/2025 exige supervisão humana no uso de IA pelo Judiciário.
Aconselhamento jurídico	O sistema não deve ser apresentado a leigos como previsão da própria condenação.
Um preditor estatístico de sentenças	Ele aplica a lei; não aprende padrões de juízes. Isso evita reproduzir vieses históricos.

2. Escopo

2.1 Dentro do escopo do MVP

Item	Detalhe
Crimes	Furto (art. 155), incluindo as formas qualificadas e o furto privilegiado; roubo (art. 157), incluindo as majorantes e as formas qualificadas.
Dosimetria	As três fases do art. 68: pena-base (art. 59), agravantes e atenuantes (arts. 61 a 67), causas de aumento e diminuição.
Fontes legais	Código Penal completo (para RAG e regras) e artigos da CF pertinentes ao direito penal (sobretudo o art. 5º).
Público	Modo ensino (estudantes) e modo apoio institucional.
Idioma	Português.

2.2 Fora do escopo (por enquanto)

Item	Motivo de ficar para depois
Outros crimes e leis especiais (ex.: Lei de Drogas)	Cada tipo penal traz regras próprias; primeiro o motor precisa estar sólido em dois crimes.
Concurso de crimes (arts. 69 a 71)	Soma ou exasperação de penas de crimes distintos é uma camada acima da dosimetria de um crime.
Regime inicial, substituição e suspensão da pena	São etapas posteriores à fixação da pena (arts. 33, 44 e 77).
Pena de multa (dias-multa)	Tem cálculo próprio (arts. 49 e 60); pode entrar numa versão 2.
Aplicação da lei no tempo	O modelo de dados já guarda a vigência, mas o motor inicialmente usa apenas a lei vigente.

Pergunta para você: Quando um usuário descrever um crime fora do escopo (por exemplo, estelionato), o que o sistema deve responder? Recusar, tentar mesmo assim, ou calcular só o que conseguir?

3. Fundamento jurídico que o sistema modela

Esta seção resume as regras que o motor de dosimetria precisa implementar. Ela não substitui o estudo do Código Penal; confirme sempre cada regra no texto compilado vigente e, se possível, valide com um professor de Direito Penal.

3.1 Antes das fases: escolher a faixa de pena

O tipo penal define a pena mínima e máxima em abstrato. Se houver **qualificadora**, ela **substitui a faixa inteira** antes de qualquer cálculo. Exemplo: o furto simples tem pena de 1 a 4 anos de reclusão; o furto qualificado do §4º tem pena de 2 a 8 anos. Já a **majorante** (causa de aumento) não troca a faixa: ela aplica uma fração na 3ª fase. Essa distinção é a primeira coisa que o seu modelo de dados precisa capturar.

3.2 As três fases (art. 68 do CP)

Fase	O que acontece	Base legal	Limites
Faixa	Seleciona a pena em abstrato (simples ou qualificada).	Tipo penal na Parte Especial	Mínimo e máximo do tipo.
1ª — pena-base	Avalia as 8 circunstâncias judiciais: culpabilidade, antecedentes, conduta social, personalidade, motivos, circunstâncias, consequências do crime e comportamento da vítima.	Art. 59	Não sai da faixa: fica entre o mínimo e o máximo.
2ª — pena intermediária	Aplica agravantes (ex.: reincidência) e atenuantes (ex.: confissão espontânea, menoridade relativa). Havendo concurso entre elas, algumas preponderam.	Arts. 61 a 67	Também não sai da faixa. A atenuante não reduz abaixo do mínimo (Súmula 231 do STJ).
3ª — pena definitiva	Aplica causas de aumento e de diminuição, geralmente em frações (1/3, 2/3, metade...).	Parte Geral e Parte Especial; art. 68, parágrafo único	Pode ultrapassar o máximo e ficar abaixo do mínimo.

3.3 Pontos de atenção que o motor precisa respeitar

Regra	Implicação no sistema
Não há fração legal fixa para cada circunstância do art. 59 nem para agravantes e atenuantes.	A jurisprudência usa critérios como 1/6 por circunstância ou 1/8 do intervalo entre mínimo e máximo. O motor deve tornar o critério configurável e visível no relatório (padrão de projeto Strategy).
Uma circunstância não pode ser usada duas vezes (bis in idem).	Se algo já qualifica o crime, não pode também agravar. O validador precisa checar isso.
Inquéritos e ações penais em curso não servem para agravar a pena-base (Súmula 444 do STJ).	O extrator deve distinguir condenação definitiva de mero processo em andamento.
No roubo circunstanciado, o aumento acima do mínimo exige fundamentação concreta, não bastando o número de majorantes (Súmula 443 do STJ).	Quando houver fração variável (ex.: 1/3 até metade), o motor usa a mínima por padrão e só aumenta se houver justificativa registrada.
Concurso de causas de aumento ou diminuição previstas na Parte Especial (art. 68, parágrafo único).	O juiz pode aplicar só a que mais aumente ou diminua. O motor deve permitir as duas opções e mostrar ambas.
Frações de dia são desprezadas (art. 11 do CP).	Defina uma regra de arredondamento única e documente-a.

3.4 Dispositivos-chave do MVP

Os parágrafos abaixo são os primeiros casos de teste do parser. Vários foram incluídos depois de 2017, por isso o PDF antigo não serve como base final. Confirme cada um no texto compilado do Planalto.

Dispositivo	Natureza	Efeito
Art. 155, caput	Tipo simples	Faixa base do furto.
Art. 155, §1º	Majorante	Repouso noturno: aumento de um terço (3ª fase).
Art. 155, §2º	Privilégio	Réu primário e coisa de pequeno valor: diminuição, substituição ou só multa.
Art. 155, §4º e seguintes (§4º-A, §4º-B, §5º, §6º, §7º)	Qualificadoras	Cada uma substitui a faixa inteira.
Art. 157, caput	Tipo simples	Faixa base do roubo.
Art. 157, §2º, §2º-A e §2º-B	Majorantes	Frações diferentes conforme o inciso (ex.: concurso de pessoas, arma de fogo).
Art. 157, §3º	Qualificadoras	Lesão grave e resultado morte (latrocínio): faixas próprias.
Arts. 59, 61 a 68	Parte Geral	Regras do próprio motor.
CF, art. 5º (XXXIX, XL, XLVI)	Princípios	Legalidade, retroatividade da lei mais benéfica e individualização da pena: usados na fundamentação.


4. Arquitetura

O sistema tem três trilhas independentes. A **ingestão** transforma a lei em dados; a **consulta** processa um caso; a **avaliação** mede se o sistema acerta.

INGESTÃO (roda quando a lei muda)



CONSULTA (cada caso)



rosa = único componente que calcula pena (sem IA)

AValiação (benchmark)



4.1 Componentes

Componente	Responsabilidade	Entrada → saída
Coletor	Baixa o HTML compilado do Planalto e registra data e hash da coleta.	URL → arquivo bruto + metadados
Parser de dispositivos	Separa artigo, parágrafo, inciso e alínea; identifica epígrafes (ex.: "Furto qualificado"); separa texto vigente de revogado.	HTML → lista de dispositivos
Parser de penas	Converte "reclusão, de um a quatro anos, e multa" em dados estruturados.	Texto → espécie, mínimo, máximo, multa
Indexador	Gera embeddings e índice de texto completo para cada dispositivo.	Dispositivos → vetores
LLM extrator	Lê o caso e preenche o objeto FatosDoCaso, com a evidência textual de cada item.	Texto do caso → JSON
Validador	Confere o schema, se os dispositivos existem na base e regras como bis in idem.	JSON → JSON válido ou erros
Motor de dosimetria	Aplica as três fases e registra cada passo.	FatosDoCaso → ResultadoDosimetria
LLM fundamentação	Redige a explicação usando apenas o passo a passo do motor e os trechos recuperados.	Resultado + trechos → texto
Auditoria	Registra entrada, versões da base e do modelo, e saída de cada análise.	Análise → log

5. Tecnologias

A stack foi escolhida para combinar com o seu foco em Java e Spring Boot, usar Python onde ele é mais prático (scripts de ingestão e avaliação) e caber nos serviços do Azure for Students.

Camada	Tecnologia	Para quê	Observação
Backend e motor	Java 21 (LTS) + Spring Boot	API REST, motor de dosimetria, validação	Motor como módulo puro, sem dependência de Spring.
Integração com LLM	Spring AI	Chamadas ao modelo, saída estruturada, embeddings	Esconda atrás da sua interface LlmClient.
Modelo de linguagem	Azure OpenAI	Extração e fundamentação	Incluído na oferta para estudantes; temperatura 0.
Embeddings	Modelo de embeddings do Azure OpenAI	Busca semântica dos dispositivos	Registre o nome do modelo junto de cada vetor.
Banco de dados	PostgreSQL + extensão pgvector	Dispositivos, tipos penais, vetores, logs	Um banco só para relacional e vetorial.
Migrações	Flyway	Versionar o schema do banco	
Ingestão	Python 3 + requests + BeautifulSoup/lxml	Baixar e parsear o HTML do Planalto	Atenção à codificação Windows-1252.
Avaliação	Python + pandas	Rodar o benchmark e calcular métricas	

Camada	Tecnologia	Para quê	Observação
Testes	JUnit 5, AssertJ, Testcontainers; pytest	Testes do motor e de integração com o banco	Testcontainers sobe um PostgreSQL real nos testes.
Frontend	React + Vite + TypeScript	Telas dos modos ensino e institucional	Alternativa mais simples: Thymeleaf.
Autenticação	Spring Security + Microsoft Entra ID	Login e perfis (estudante, instituição, admin)	No MVP local, um usuário fixo basta.
Ambiente local	Docker + Docker Compose	Subir banco e API com um comando	
Versionamento e CI	Git + GitHub + GitHub Actions	Rodar testes a cada push; publicar imagens	Repositório público vira portfólio.

6. Modelo de dados

Abaixo estão as tabelas principais e seus campos. Tipos exatos, índices e restrições ficam por sua conta; as perguntas ao fim da seção apontam as decisões mais importantes.

Tabela	Campos principais	Observações
norma	id, sigla (CP, CF, ADCT), nome, url_fonte	ADCT separado da CF, porque a numeração dos artigos se repete.
dispositivo	id, norma_id, rotulo (ex.: CP.art155.§4.IV), artigo, paragrafo, inciso, alinea, epigrafe, texto, vigente_desde, vigente_ate, alterado_por, coletado_em, hash_texto	Um mesmo rótulo pode ter várias versões ao longo do tempo.
tipo_penal	id, dispositivo_id, especie (reclusão/detenção), pena_min, pena_max, tem_multa, eh_qualificadora, tipo_base_id	Qualificadora aponta para o tipo base.
causa_modificada	id, dispositivo_id, direcao (aumento/diminuição), fracao_min, fracao_max, origem (parte geral/especial)	Fração guardada como numerador e denominador.
circunstancia	id, codigo, categoria (judicial, agravante, atenuante), dispositivo_id, preponderante	Catálogo fechado que o extrator usa.
dispositivo_vetor	dispositivo_id, modelo_embedding, vetor	Índice pgvector.
analise	id, usuario_id, modo, texto_entrada, fatos_json, resultado_json, versao_base, versao_modelo, criado_em	Auditoria; o texto de entrada pode exigir anonimização ou retenção limitada.
usuario	id, email, perfil, instituicao	Perfis: estudante, instituição, admin.
caso_benchmark	id, fonte, texto, anotacao_json, conjunto (desenvolvimento/teste)	Gold set da avaliação.

6.1 Decisões de modelagem

Decisão	Recomendação
Unidade da pena	Guardar internamente em dias (inteiros) e formatar como anos, meses e dias só na apresentação. Defina e documente a convenção de conversão.
Frações	Nunca usar double. Use um tipo Fracao com numerador e denominador inteiros, e arredonde uma única vez, no fim de cada fase.
Identidade de um dispositivo	O rótulo sozinho não basta quando há versões: a chave precisa combinar rótulo e vigência.
Texto revogado	Guardar com vigente_ate preenchido em vez de descartar. É o que permitirá, no futuro, aplicar a lei vigente na data do fato.

Pergunta para você: No art. 155, o §1º aplica uma fração e o §4º troca a faixa. Em qual tabela cada um deles vira registro, e como o motor descobre qual faixa usar quando o caso tem ao mesmo tempo uma qualificadora e uma majorante?

7. Contratos entre os componentes

7.1 FatosDoCaso (saída do extrator, entrada do motor)

É o contrato mais importante do sistema. Cada item extraído precisa vir com a **evidência**: o trecho do texto do caso que o justifica. Isso permite checagem humana e reduz alucinação.

Campo	Conteúdo	Regra
tipo_penal	Rótulo do dispositivo (ex.: CP.art157)	Deve existir na base.
qualificadoras	Lista de rótulos + evidência	Pode ser vazia.
circunstancias_judiciais	Para cada uma das 8 do art. 59: favorável, neutra ou desfavorável + evidência	Sem evidência, o valor é neutra.
agravantes / atenuantes	Lista de códigos do catálogo + evidência	Validador aplica bis in idem.
causas_aumento / causas_diminuicao	Rótulo + fração escolhida + justificativa	Fração dentro do intervalo legal.
informacoes_ausentes	O que o texto não informa (ex.: antecedentes)	Mostrado ao usuário, nunca inventado.
data_do_fato	Data, se informada	Reservado para aplicação da lei no tempo.

7.2 ResultadoDosimetria (saída do motor)

Campo	Conteúdo
faixa_aplicada	Mínimo, máximo e dispositivo de origem (simples ou qualificado).
pena_base, pena_intermediaria, pena_definitiva	Valores em dias e formatados.
passos	Lista ordenada: fase, regra aplicada, dispositivo, valor antes, valor depois, motivo.
criterio_quantum	Qual estratégia de cálculo foi usada na 1ª e 2ª fases.
alertas	Ex.: atenuante não aplicada por causa da Súmula 231; informação ausente.

7.3 Endpoints da API (sugestão)

Método e rota	Função
POST /analises/extrair	Recebe o texto do caso e devolve o FatosDoCaso para o usuário revisar.
POST /analises/calcular	Recebe o FatosDoCaso confirmado e devolve ResultadoDosimetria + fundamentação.
GET /analises/{id}	Recupera uma análise registrada.
GET /dispositivos/{rotulo}	Retorna o texto vigente de um dispositivo.
POST /ensino/comparar	Recebe a dosimetria do aluno e aponta onde diverge da do sistema.

Separar extração e cálculo em duas chamadas é proposital: entre elas, o usuário confirma ou corrige o que o LLM extraiu.

8. Fases de construção

Cada fase termina com algo que funciona sozinho. Não avance sem cumprir o critério de pronto. As estimativas supõem cerca de 10 horas por semana.

Fase 1 — Ingestão da lei

Duração estimada: 2 a 3 semanas. **Objetivo:** Transformar o Código Penal (e os artigos pertinentes da CF) em dados estruturados no PostgreSQL.

Entrega	Descrição
Coletor	Script que baixa o HTML compilado, grava o arquivo bruto com data e hash.
Parser de dispositivos	Hierarquia artigo → parágrafo → inciso → alínea, com epígrafes; separação vigente/revogado.
Parser de penas	Conversão de penas por extenso ("de um a quatro anos", "de 2 (dois) a 5 (cinco) anos") para dias.
Carga no banco	Migrações Flyway e script de carga idempotente (rodar duas vezes não duplica).
Testes	Testes com trechos reais do Planalto salvos como fixtures.

Pronto quando: Consultar CP.art155.§4.IV devolve o texto do concurso de pessoas; a pena do art. 155, caput, sai como reclusão de 365 a 1.460 dias com multa (ou a convenção de dias que você definir); o art. 157, §2º-A, existe na base.

Pergunta para você: O PDF antigo tem cabeçalhos no meio dos artigos; o HTML tem texto riscado. Qual característica do HTML indica o texto revogado, e como o seu parser a detecta?

Fase 2 — Motor de dosimetria

Duração estimada: 3 semanas. **Objetivo:** Implementar as três fases como código puro, sem IA e sem banco, recebendo FatosDoCaso preenchido à mão.

Entrega	Descrição
Tipos de valor	Pena (em dias) e Fracao (numerador e denominador), imutáveis.
Calculadoras	Uma por fase, cada uma recebendo o valor da anterior e devolvendo novo valor + passo registrado.
Estratégias de quantum	Interface com ao menos duas implementações (ex.: 1/6 sobre o mínimo; 1/8 do intervalo).
Regras de limite	Faixa na 1ª e 2ª fases (Súmula 231); liberdade na 3ª; art. 68, parágrafo único.
Testes	Pelo menos 10 dosimetrias reais reproduzidas, tiradas de sentenças ou manuais.

Pronto quando: Os 10 casos de teste passam, e cada resultado traz o passo a passo completo.

Pergunta para você: Na 2ª fase a pena não pode ficar abaixo do mínimo, mas na 3ª pode. Em qual classe mora essa regra, e como você evita que ela vaze para a fase errada?

Fase 3 — Extração com LLM

Duração estimada: 2 semanas. **Objetivo:** Converter texto livre em FatosDoCaso confiável.

Entrega	Descrição
Prompt de extração	Instruções, catálogo fechado de circunstâncias, exemplos e exigência de evidência por item.
Saída estruturada	JSON Schema imposto ao modelo; temperatura 0.
Validador	Schema, existência dos rótulos, bis in idem; em caso de erro, até 2 novas tentativas com o erro informado.
Casos de desenvolvimento	20 descrições de caso escritas por você, com a resposta esperada.

Pronto quando: Nos 20 casos, o tipo penal é identificado corretamente em todos e as circunstâncias na grande maioria; nenhum item aparece sem evidência.

Pergunta para você: O texto do caso pode conter frases como "ignore as instruções anteriores". Como o seu prompt e o validador se protegem disso?

Fase 4 — Fundamentação com RAG

Duração estimada: 2 semanas. **Objetivo:** Explicar o resultado em linguagem jurídica, citando apenas dispositivos da base.

Entrega	Descrição
Unidade de indexação	Um dispositivo por registro (não blocos de tamanho fixo), com rótulo e epígrafe como metadados.
Busca híbrida	Combinação de busca vetorial (pgvector) e texto completo em português do PostgreSQL.
Prompt de fundamentação	Recebe o passo a passo do motor e os trechos recuperados; cita por rótulo.
Verificador de citações	Pós-processamento que confere se cada rótulo citado existe e foi recuperado.

Pronto quando: Em todos os casos de desenvolvimento, zero citações inválidas, verificado automaticamente.

Pergunta para você: Se o LLM escrever uma pena diferente da calculada pelo motor, qual dos dois vale, e como você detecta a divergência?

Fase 5 — Benchmark

Duração estimada: 2 a 3 semanas. **Objetivo:** Medir o sistema contra decisões reais.

Entrega	Descrição
Coleta	30 a 50 sentenças ou acórdãos de furto e roubo com dosimetria explícita (TJs, STJ).
Anotação	Planilha com tipo penal, circunstâncias e penas de cada fase, segundo o juiz.
Divisão	Conjunto de desenvolvimento e conjunto de teste; o de teste não é usado para ajustar prompts.
Script de avaliação	Roda o sistema, compara e gera um relatório de métricas.

Pronto quando: Você tem números de acerto do tipo penal, qualidade da extração das circunstâncias e erro médio (em dias) da pena-base e da pena final.

Pergunta para você: Se juiz e sistema chegam à mesma pena por caminhos diferentes, isso conta como acerto?

Fase 6 — API, interface e modos de uso

Duração estimada: 3 semanas. **Objetivo:** Tornar o sistema utilizável por quem não é você.

Entrega	Descrição
API	Endpoints da seção 7.3, com tratamento de erros e validação de entrada.
Tela de revisão	O usuário confirma ou corrige cada item extraído antes do cálculo.
Modo ensino	O aluno informa sua dosimetria; o sistema aponta em que fase divergiram.
Modo institucional	Resultado como sugestão, com registro completo e aviso de uso.
Autenticação	Perfis estudante, instituição e admin.

Pronto quando: Um estudante de Direito usa o sistema sem sua ajuda e consegue dizer de onde veio cada número.

Pergunta para você: Que informações o modo ensino deve esconder até o aluno enviar a própria resposta?

Fase 7 — Implantação no Azure e piloto

Duração estimada: 2 semanas + piloto. **Objetivo:** Colocar no ar com custo controlado e testar com usuários reais.

Entrega	Descrição
Infraestrutura	Serviços da seção 10, todos na região Brazil South.
CI/CD	GitHub Actions: testes, build da imagem, deploy.
Custos	Alerta de orçamento configurado no primeiro dia.
Piloto	Uma turma de Direito Penal, com um professor acompanhando e formulário de feedback.

Pronto quando: Uma turma usou o sistema num trabalho e você tem a lista de erros encontrados.

Pergunta para você: Quais dados de uso você precisa coletar no piloto para saber se o sistema ajudou a aprender?

Cronograma resumido

Fase	Semanas (acumulado)
1. Ingestão	1 a 3
2. Motor	4 a 6
3. Extração	7 a 8
4. RAG	9 a 10
5. Benchmark	11 a 13
6. API e interface	14 a 16
7. Azure e piloto	17 a 18, e piloto durante um semestre

9. Avaliação

Métrica	Como calcular	Por que importa
Acurácia do tipo penal	Proporção de casos com tipo e qualificadora corretos.	Erro aqui invalida todo o resto.
Precisão e recall das circunstâncias	Comparação item a item com a anotação.	Mostra se o extrator inventa (precisão) ou deixa passar (recall).
Erro médio da pena-base	Média da diferença absoluta, em dias.	Mede a 1ª fase isoladamente.
Erro médio da pena definitiva	Média da diferença absoluta, em dias.	Resultado final visível ao usuário.
Acerto por fase	Em que fase a divergência começa.	Diz onde melhorar.
Citações inválidas	Proporção de citações fora da base.	Deve ser zero.

Separe o desempenho do **motor** do desempenho do **extrator**: rode o motor também com o `FatosDoCaso` anotado por você. Se o resultado continuar errado, o problema está no motor; se ficar certo, está na extração.

10. Infraestrutura no Azure

Serviço	Função no projeto
Azure Container Apps	Hospeda a API Spring Boot em contêiner; escala a zero quando ninguém usa.
Container Apps Jobs	Roda a ingestão da lei sob demanda ou agendada.
Azure Database for PostgreSQL (Flexible Server)	Banco relacional com a extensão pgvector habilitada.
Azure OpenAI	Modelo de linguagem e modelo de embeddings.
Azure Static Web Apps	Hospeda o frontend React.
Azure Blob Storage	Guarda os arquivos brutos coletados do Planalto, versionados.
Azure Key Vault	Segredos: senhas do banco e chaves de API.
Application Insights	Logs, métricas e rastreamento de erros.
Microsoft Entra ID	Autenticação e perfis de usuário.
Registro de imagens	GitHub Container Registry (gratuito) ou Azure Container Registry.

10.1 Custos

A conta Azure for Students dá crédito anual e serviços gratuitos, mas o crédito acaba. Quando ele termina sem migração para uma assinatura paga, os recursos são desativados. Por isso:

Prática	Detalhe
Desenvolver localmente	Fases 1 a 6 rodam com Docker Compose no seu computador; a nuvem só entra na Fase 7.
Alerta de orçamento	Configure no Azure Cost Management antes de criar qualquer recurso.
Menor camada possível	Banco na menor camada que suporte pgvector; Container Apps com escala a zero.
Cuidado com o LLM	Limite de requisições por usuário e cache de embeddings; cada chamada consome crédito.
Confirmar gratuidades	Verifique no portal quais serviços estão no nível gratuito da sua conta antes de criá-los.

10.2 Ambientes

Ambiente	Onde	Uso
Local	Seu computador (Docker Compose)	Desenvolvimento diário e testes.
CI	GitHub Actions	Testes automáticos a cada push.
Produção	Azure, Brazil South	Piloto com usuários reais.

11. Segurança, LGPD e governança

Tema	Medida
Resolução CNJ 615/2025	Regula IA no Judiciário, com classificação de risco, supervisão humana e transparência. Leia a norma antes da Fase 6 e desenhe o modo institucional a partir dela.
Supervisão humana	Usuário confirma a extração antes do cálculo; resultado sempre rotulado como sugestão.
Explicabilidade	Passo a passo completo, critério de quantum visível e dispositivos citados com link.
Dados pessoais (LGPD)	Orientar a anonimização antes do envio; retenção mínima dos textos; nenhum uso de dados de usuários para ajustar o sistema sem autorização.
Injeção de prompt	Texto do caso tratado como dado, delimitado no prompt; validação independente da saída.
Segredos	Somente no Key Vault ou em variáveis de ambiente; nunca no repositório.
Viés	O sistema aplica regras legais em vez de aprender com decisões passadas; mesmo assim, analise no benchmark se os erros se concentram em algum tipo de caso.
Aviso de uso	Em toda tela: ferramenta de estudo e apoio, não aconselhamento jurídico nem decisão.

12. Estrutura do repositório (sugestão)

```

ia-dosimetria/
├── ingestao/                # Python: coletor, parsers, carga
│   ├── coletor/
│   ├── parsers/
│   └── tests/fixtures/      # trechos reais do Planalto
├── backend/                 # Java + Spring Boot
│   ├── dosimetria-core/    # motor puro, sem Spring
│   ├── api/                # controllers, serviços, segurança
│   ├── llm/                # interface LlmClient + implementação
│   └── src/main/resources/db/migration/ # Flyway
├── frontend/               # React + Vite
├── avaliacao/              # benchmark, anotações, métricas
│   ├── casos/
│   └── relatorios/
├── infra/                  # docker-compose, arquivos do Azure
├── docs/                   # decisões de arquitetura (ADRs)
└── .github/workflows/      # CI/CD

```

Registre cada decisão importante (ex.: "pena guardada em dias", "critério de quantum padrão") em um arquivo curto na pasta docs. Isso ajuda você no futuro e impressiona em entrevistas.

13. Riscos e mitigação

Risco	Impacto	Mitigação
Erro jurídico nas regras do motor	Alto	Validar regras com um professor de Direito Penal; casos de teste tirados de sentenças reais.
LLM inventa circunstâncias ou artigos	Alto	Evidência obrigatória, validador, confirmação humana, verificador de citações.
Lei muda depois da coleta	Médio	Coleta periódica, hash do texto, vigência por dispositivo.
Crédito do Azure acaba	Médio	Desenvolvimento local, alerta de orçamento, escala a zero.
Escopo cresce demais	Alto	Manter furto e roubo até o benchmark estar pronto.
Dados pessoais em casos reais	Alto	Anonimização, retenção mínima, região no Brasil.
Uso indevido como aconselhamento	Médio	Avisos claros, login, foco em ensino.

14. Fontes oficiais

Fonte	Endereço	Uso
Código Penal compilado (Planalto)	planalto.gov.br/ccivil_03/decreto-lei/del2848compilado.htm	Base final da ingestão.
Constituição compilada (Planalto)	planalto.gov.br/ccivil_03/constituicao/constituicaocompilado.htm	Artigos constitucionais.
Coletânea básica penal, 16ª ed. (Senado)	www2.senado.leg.br — Biblioteca Digital do Senado	Referência em PDF, atualizada até janeiro de 2026.
Resolução CNJ 615/2025	cnj.jus.br	Governança de IA no Judiciário.
Jurisprudência	Portais do STJ e dos Tribunais de Justiça; API pública do DataJud (CNJ)	Casos do benchmark.

15. Glossário

Termo	Significado
Dosimetria	Processo de fixação da pena pelo juiz.
Sistema trifásico	Método do art. 68 do CP: pena-base, pena intermediária e pena definitiva.
Pena-base	Resultado da 1ª fase, a partir das circunstâncias do art. 59.
Qualificadora	Circunstância que cria uma nova faixa de pena (mínimo e máximo próprios).
Majorante / minorante	Causa de aumento / diminuição aplicada em fração na 3ª fase.
Agravante / atenuante	Circunstâncias da 2ª fase (arts. 61 a 66).
Bis in idem	Uso da mesma circunstância duas vezes na dosimetria, o que é vedado.
Quantum	Quanto cada circunstância aumenta ou diminui a pena.
RAG	Geração aumentada por recuperação: o LLM responde com base em trechos buscados numa base.
Embedding	Vetor numérico que representa o significado de um texto, usado na busca semântica.
Gold set	Conjunto de casos anotados manualmente, usado como gabarito na avaliação.